Guía para correr IA en local

Cómo instalar y usar Ollama, LM Studio, CanIRun.ai, whichllm y llmfit

Antes de descargar cualquier modelo de IA en tu ordenador conviene verificar qué soporta tu hardware. Esta guía reúne las cinco herramientas para eso: dos para descargar y ejecutar modelos (Ollama y LM Studio) y tres para comprobar antes qué modelo le conviene a tu equipo (CanIRun.ai, whichllm y llmfit). Para cada una: para qué sirve, cómo se instala y cómo se usa.

1. Ollama

Ejecutar modelos de IA en local desde la terminal

Para qué sirve

Ollama descarga y ejecuta modelos de lenguaje directamente en tu ordenador. Una vez descargado un modelo, funciona sin conexión a internet. Se maneja principalmente desde la terminal y, al instalarse, deja corriendo en segundo plano un servidor local compatible con la API de OpenAI, así que cualquier aplicación o script puede conectarse a tus modelos locales.

Cómo se instala

- **macOS y Windows:** entra en ollama.com, descarga el instalador para tu sistema y ábrelo. El instalador añade el comando `ollama` a la terminal automáticamente.
- **Linux:** abre una terminal y ejecuta el script oficial de instalación.

```
curl -fsSL https://ollama.com/install.sh | sh
```

Para comprobar que quedó instalado correctamente:

```
ollama --version
```

Cómo se usa

- Descargar un modelo y abrir el chat en un solo paso (la primera vez lo descarga, las siguientes lo abre directamente):

```
ollama run llama3.2
```

- Descargar un modelo sin abrir el chat todavía:

```
ollama pull <nombre-del-modelo>
```

- Ver los modelos que ya tienes descargados:

```
ollama list
```

- Dentro del chat, escribe `/bye` para salir.
- El servidor local queda escuchando en el puerto 11434, así que puedes conectar otras apps a esa API sin pasar por la terminal cada vez.

2. LM Studio

Descargar y chatear con modelos con interfaz gráfica

Para qué sirve

LM Studio es una aplicación de escritorio con interfaz gráfica para descargar, explorar y chatear con modelos de lenguaje en local, sin necesidad de usar la terminal. Es la alternativa visual a Ollama: mismos modelos, interfaz de por medio.

Cómo se instala

Entra en lmstudio.ai, descarga el instalador correspondiente a tu sistema (Windows, macOS o Linux) y ejecútalo. No pide cuenta ni registro para usarse en local.

Cómo se usa

- Abre la pestaña **Discover** (icono de lupa) para buscar modelos. Puedes escribir el nombre (por ejemplo, "gemma 3") o pegar directamente una URL de Hugging Face.
- Cada modelo aparece en varias versiones cuantizadas (Q4_K_M, Q5_K_M, Q8...). Para empezar, Q4_K_M es el equilibrio recomendado entre tamaño y calidad.
- LM Studio marca junto a cada modelo si tu hardware lo soporta cómodamente, antes de que lo descargues.
- Pulsa **Download**. Cuando termine, ve a la pestaña **Chat**, selecciona el modelo en la parte superior y empieza a escribir.
- Si quieres usar tus modelos locales desde otra app o desde código, la pestaña **Developer** permite activar un servidor local compatible con la API de OpenAI.

3. CanIRun.ai

Comprobar qué modelos soporta tu ordenador, desde el navegador

Para qué sirve

CanIRun.ai es una web gratuita que analiza el hardware de tu ordenador (CPU, GPU y RAM) directamente desde el navegador y te dice qué modelos de IA puede ejecutar tu equipo, sin instalar nada. Es el paso previo antes de descargar cualquier modelo en Ollama o LM Studio.

Cómo se instala

No requiere instalación. Solo entra en la web desde tu navegador:

https://www.canirun.ai/

Cómo se usa

- Al abrir la web, detecta automáticamente tu hardware usando WebGPU (el navegador puede pedir permiso para esto).
- En unos segundos muestra el catálogo de modelos compatibles con tu equipo (cerca de 60 modelos), con una puntuación de compatibilidad y los requisitos de VRAM de cada uno.

- Puedes filtrar por tipo de tarea (chat, código, razonamiento, visión), proveedor, licencia o tamaño de contexto, y ordenar los resultados por puntuación.
- La sección **Tier List** clasifica los modelos según tu hardware, y puedes exportar los resultados como imagen.
- Todo el análisis ocurre en el navegador: no se envían datos a servidores externos.

4. whichllm

Recomendación de modelos por línea de comandos

Para qué sirve

whichllm es una herramienta de terminal que detecta tu hardware y recomienda qué modelo de Hugging Face te conviene, no solo el más grande que técnicamente cabe en tu equipo, sino el que mejor puntúa en benchmarks reales (LiveBench, Arena, Artificial Analysis...). También permite simular hardware que no tienes, planificar una compra de GPU o lanzar un chat directamente desde la terminal.

Cómo se instala

- Sin instalación permanente, con uv ya instalado:

```
uvx whichllm@latest
```

- Instalación persistente:

```
uv tool install whichllm
```

- También disponible por Homebrew o pip:

```
brew install andyyyy64/whichllm/whichllm    |    pip install whichllm
```

Cómo se usa

- Ejecuta el comando sin argumentos para ver el ranking de los mejores modelos para tu hardware, detectado automáticamente:

```
whichllm
```

- Simular una tarjeta gráfica que no tienes (útil si estás valorando comprarla):

```
whichllm --gpu "RTX 4090"
```

- Quedarte solo con modelos que caben enteros en tu VRAM:

```
whichllm --gpu-only
```

- Chatear directamente con un modelo sin instalarlo tú mismo:

```
whichllm run "qwen 2.5 1.5b gguf"
```

- Saber qué GPU necesitarías para un modelo concreto:

```
whichllm plan "llama 3 70b"
```

5. llmfit

Interfaz interactiva en terminal para ajustar modelos a tu hardware

Para qué sirve

llmfit detecta tu RAM, CPU y GPU y puntúa cientos de modelos según calidad, velocidad, ajuste a tu hardware y ventana de contexto, para decirte cuáles corren bien en tu máquina. Incluye una interfaz interactiva en terminal (TUI) además del modo clásico de línea de comandos, y se integra con Ollama, llama.cpp, MLX, Docker Model Runner y LM Studio.

Cómo se instala

- **Windows** (con Scoop instalado):

```
scoop install llmfit
```

- **macOS / Linux**, con Homebrew:

```
brew install llmfit
```

- **macOS / Linux**, instalación rápida por script:

```
curl -fsSL https://llmfit.axjns.dev/install.sh | sh
```

- También disponible por Docker:

```
docker run ghcr.io/alexsjones/llmfit
```

Cómo se usa

- Ejecuta el comando sin argumentos para abrir la interfaz interactiva (TUI):

```
llmfit
```

- Dentro de la TUI: se navega con `j/k`, se busca con `/`, se filtra con `f` y `a`, se ordena con `s`, y con `p` entras al modo Plan, que estima el hardware necesario para un modelo concreto.
- Si prefieres la terminal clásica sin interfaz visual:

```
llmfit --cli
```

- Ver solo la información detectada de tu sistema:

```
llmfit system
```

- Buscar un modelo concreto o pedir recomendaciones directas:

```
llmfit search "llama 8b"
llmfit recommend --json --limit 5
```

- También cuenta con un dashboard web propio:

```
llmfit dashboard
```

Enlaces

- Ollama: https://ollama.com/
- LM Studio: https://lmstudio.ai/
- CanIRun.ai: https://www.canirun.ai/
- whichllm: https://github.com/Andyyyy64/whichllm
- llmfit: https://www.llmfit.org/#install